

Aula RAG

Proyecto final | Informe de diseño y verificación | 2 de octubre de 2026

Dominio y corpus.

Consulta documental sobre fundamentos de IA, aprendizaje automático, embeddings, arquitectura RAG y validación. El corpus contiene cinco documentos Markdown originales bajo CC0, con 3,926 palabras y 18 chunks realmente indexados. Google genera los embeddings con gemini-embedding-001: 768 dimensiones normalizadas, RETRIEVAL_DOCUMENT para textos y RETRIEVAL_QUERY para preguntas. El modelo y las dimensiones son iguales en ambos caminos.

Partición y recuperación.

Se usan ventanas de 300 palabras con 60 de solapamiento. Este equilibrio conserva contexto sin enviar documentos completos; el solapamiento protege explicaciones que caen en límites, a costa de redundancia. Los chunks conservan origen, página e índice. En PDF no cruzan páginas. Chroma recupera cuatro vecinos por defecto, configurables entre uno y diez; el score es uno menos la distancia coseno, no una probabilidad de certeza.

Abstención y citas.

Un índice vacío o la ausencia de vecinos con score de al menos 0.35 produce abstención. Si hay fragmentos, Gemini debe responder solo con esa evidencia y abstenerse cuando no cubra la pregunta completa. Devuelve respuesta, decisión y referencias estructuradas; la API verifica índices y consistencia, normaliza citas agrupadas y agrega etiquetas seleccionadas si faltan. Referencias inválidas producen abstención. Revisar índices existentes no demuestra soporte semántico: también se inspecciona el texto citado. El umbral es inicial y no constituye una frontera universal calibrada.

Responsabilidades y conversación.

Google AI calcula los vectores y Gemini redacta en español con citas; la configuración validada usa gemini-3.8-flash con razonamiento bajo. Chroma guarda vectores, texto y metadatos en disco y busca vecinos usando embeddings proporcionados por la API. FastAPI centraliza ingestión y consulta; Streamlit es exclusivamente su cliente HTTP. Hasta seis turnos del mismo filtro ayudan a reformular seguimientos, pero las respuestas previas no son evidencia factual. La biblioteca permite filtrar, reindexar y eliminar un origen sin borrar el archivo original.

Verificación y límites.

Pasaron 68 pruebas locales con Chroma real y Google simulado exclusivamente en tests. Con Google real, tres preguntas del dominio produjeron respuestas citadas, revisadas contra sus fuentes, y dos preguntas sin datos disponibles se abstuvieron, incluida la contraseña del WiFi. El reinicio real de FastAPI conservó los cinco documentos y 18 chunks, seguido de una consulta correcta sin reingestión. Los registros y capturas se incluyen en evidence/. Se observaron errores temporales y de cuota: se registran como fallos del proveedor, no como abstenciones. La muestra no demuestra calidad general. El sistema usa un proceso API; PDF escaneados necesitan OCR externo, los conteos globales requieren cobertura exhaustiva y las escrituras de varios archivos no tienen una transacción conjunta.